

阿里云第一期充值申请说明

合伙人审批稿 | 2026 年 9 月 7 日

申请主体：上海生声不息科技有限公司（实际充值账号实名认证及签约主体须由财务确认）

一、申请事项

建议批准第一期阿里云账户首次充值 **100,000 元**，并将六个月基础云支出审批上限设为 **120,000 元**。其中 100,000 元为计划内资源与 API 资金，另 20,000 元为须再次审批的扩容预留，不立即充值、不自动消费。

本次申请用于主站、采集站及后续应用的基础设施与少量模型 API，不包括 GPU 采购或租赁。现有奇绩算力支持优先沿用；两台 8 卡 GPU 裸机作为另一项询价与技术验证计划，另行决策。

审批口径	金额	含义
首次账户充值	100,000 元	现金进入公司控制的阿里云账户；不等于当期费用全部发生
三个月支出检查点	不超过 60,000 元	评估采集、质量、稳定性与实际账单；不是额外申请
六个月基础云预算上限	120,000 元	含上述充值及 20,000 元待批扩容额；不是累计 220,000 元
政策及赠送额度	预算抵减按 0 元	获批且可实际抵扣后，才减少现金消耗
GPU 及训练存储专项	本次不审批	裸机、50TB 训练持久存储与高速网络另行报价

二、这笔投入要支持什么

第一期周期 3—6 个月，服务约 1,000 名用户，目标完成约 20,000 小时语音采集，支持 10 名开发者协作、主站及采集站运行，并为后续应用复用账号、存储与后台能力。重点是提升系统对用户意图的理解，不是纠正用户的语音。

建议以六个月作为运营基线，三个月作为加速情景。 延长周期能降低日均采集和高峰组织压力，但固定云资源占用时间更长，不能理解为总成本一定更低。

三、建议审批结论

同意本次 100,000 元充值及 120,000 元六个月上限，但充值执行以账号与合同核验完成为前提。若一次性充值没有书面折扣、赠额或明确用量依据，应由申请人向合伙人提出分批充值替代方案，不为尚未确认的补贴锁定现金。

投入依据：规模、现状与交付边界

四、20,000 小时意味着什么

以下按 3 个月 90 天、6 个月 180 天、每天集中采集 8 小时测算，属于容量假设，不是现有系统承诺。

项目	三个月完成	六个月完成
日均有效录音时长	约 222 小时	约 111 小时
采集窗口内平均同时录音	约 28 人	约 14 人
峰值上传设计场景	80—150 路	40—80 路
每人平均录音投入	共 20 小时；约 13.3 分钟/日	共 20 小时；约 6.7 分钟/日

每人 20 小时仅为算术均值，不应成为强制采集负担；需验证参与率、退出率、休息与重录时间。若目标是 20,000 小时“可训练有效数据”，实际录制量还需除以合格率，不能直接将原始录音时长视作训练入库量。

16kHz、单声道、16-bit PCM 约 115.2MB/小时，20,000 小时约 2.304TB。原始音频、标准化副本、重录留痕、数据版本和备份合计按 6—10TB 业务存储规划。单位采用十进制 TB，训练 checkpoint 大仓不在此容量内。

每条 10 秒约产生 720 万条录音；按每条约 4—7 次控制请求，三至六个月约 3,000 万—5,000 万次业务 API 请求。音频主体直传 OSS，Backend 只处理授权、签名、完成回执和进度等控制操作。该估算不含无限轮询、重复补传及未来新增应用流量。

五、不是从零建设，但尚未达到规模化交付

已有 Web 录音与 OSS 直传、登录授权、录音重试/撤回与状态管理、自研个性化 ASR 接入、DashScope 实时回退、LLM 处理、少量 TTS 和 LiveKit 语音主链。第二品牌已有配置骨架；单 Agent Worker 已有 8 路完整 RTC 链路验证记录。[L1]

尚未完成 1,000 用户规模验证、80—150 路采集峰值压测、双 Backend 多实例安全、持久事件队列、跨实例幂等与账号互斥、第二 Agent Worker、批量质检/结算及 20,000 小时生产数据闭环。购买服务器不等于这些工作自动完成。

特别前提：当前采集过程包含实时识别。两个按 8 路验证推进的 Worker 不等于能够承接 80—150 名同时使用实时识别的采集用户。必须先验证“采集可持续、识别可限流或排队”的路径，或另行扩充实时资源；本预算不承诺 150 路实时 AI 会话。[L1、L2]

预算分配与资源用途

六、内部审批分配表

单位：人民币元。原始飞书资源、价格表未提供，本表是为审批补齐的**建议额度分配**，不是阿里云报价，也不表示已经购买。实际以相同地域、SKU、期限、税费和流量条件下的书面报价替换；超出上限须重申。

费用类别	三个月	六个月	用途与边界
CPU 计算与系统盘	18,000	40,000	前端、Backend、LiveKit、Agent 及批处理
业务 OSS 与备份存储	5,000	10,000	6—10TB 容量规划；按实际占用月份计费
公网、负载均衡与流量	7,000	16,000	出网、TURN、OSS 下载、请求与必要网络服务
状态服务与数据可靠性	4,000	10,000	必要缓存、数据库备份等，不默认重建数据库
安全、日志与监控	3,000	7,000	访问审计、告警、必要安全产品
研发、镜像与预发布	3,000	9,000	镜像仓库、构建及临时验证资源
模型 API 备用金	8,000	8,000	同一 20,000 小时目标，按总用量而非月份翻倍
计划内合计	48,000	100,000	按阶段开通，不要求首日全量启用
待审批扩容预留	12,000	20,000	三个月额度包含于六个月预留，不相加
审批上限	60,000	120,000	三个月为阶段检查点，六个月为总上限

七、基础资源建议

节点用途	数量×单台规格	小计 vCPU／内存
主前端	1×4 核 8GB	4 核／8GB
第二前端、预发布及有界批处理	1×8 核 16GB	8 核／16GB
Backend 控制面	2×4 核 8GB	8 核／16GB
LiveKit 实时媒体	1×8 核 16GB	8 核／16GB
Agent Worker	2×8 核 16GB	16 核／32GB
合计	7 台	44 核／88GB

此为重建建议，不是已知原表。第二前端仅用预留资源承接有上限的质检、导出任务，持续积压时单独询价，不与在线 Agent 争抢资源。

数据库/认证继续以现有 Supabase 事实源为准，缓存或持久队列不包含在 7 台中；如采购阿里云托管产品，从对应预算项支付并逐项报价。现有 Supabase 等外部厂商订阅不能用阿里云余额支付，应由财务另列既有成本，不能据此宣称已覆盖全部基础设施费用。

API 费用、政策与现金控制

八、API 成本可控的条件

自研 ASR 为主，云端 ASR 建议封顶总音频量 10%，即全周期累计 2,000 小时，包含回退、对照和补充实时识别的收费音频，不包含免费“想当然”抵扣。六个月约 333 小时/月、三个月约 667 小时/月只是计划节奏，须设置累计控制及例外审批。

按当前代码默认的千问实时 ASR 型号、百炼北京地域公开价 0.00033 元/秒示例，2,000 小时约 2,376 元；若误配成 20,000 小时全量调用，则约 23,760 元，已明显超过 API 备用金。价格只用于量级校验，实际地域、模型版本和计费秒数由账单确认。[A2、L3]

LLM 优先沿用经任务评测合适的 Flash，复杂任务才切 Plus；纠错、对话、报告与记忆整理分别统计输入/输出 Token。举例：720 万条各一次处理、每次 300 输入+100 输出 Token，以 qwen-flash 北京短上下文公开价 0.15 元/百万输入 Token、1.5 元/百万输出 Token 估算约 1,404 元。该例不含历史上下文、重试、多轮对话和 Plus 升级，不能作为完整报价。[A2]

因此 8,000 元可作有限用量下的备用金，不保证任意用量。建议内部暂分 ASR 3,000 元、LLM 3,500 元、TTS 500 元、异常重试 1,000 元；这些都是建议控制值，尚未配置。预算预警不能替代应用侧限流；达到限额应停止非必要批处理、保留本地录音与待处理队列，必要回退另行审批。

九、补贴与优惠不作为充值前提

百炼公开页出现“超 7000 万免费 Tokens”，同页也出现“超 1 亿 Tokens”表述，说明宣传入口不宜直接转换为本账户权益。是否新客、哪些模型、额度有效期及抵扣方式，必须以账户领取记录和书面规则为准。Token Plan 订阅、活动赠额、人民币抵扣金与地方财政券不是同一项权益。[A1]

结合政策 PDF：余杭需取得 2026 修订细则和最终算力伙伴名单；杭州额度申领与兑付分开，2026 年度额度申领截至 12 月 10 日；滨江新措施 2026 年 9 月 11 日起施行，当前 9 月 7 日尚未施行；上海市级算力券明确不包括存储、网络、安全等服务，不能将整笔充值作为合格算力费用。[P1—P4]

若项目从 2026 年 9 月启动并运行六个月，将跨至 2027 年。2026 通知不能证明 2027 服务费用可补，应按服务期逐月拆账。奇绩免费算力不假定产生本公司可申报的现金租赁支出。

主体、项目、合同、付款、发票与资源使用应一致。先确认真实经营与费用归属，不为补助上限重复设立子公司，不追溯搬移历史费用、不重复申报。具体资格和财税处理由财务、专业顾问及主管部门核定。

执行安排、审批与依据

十、开通与验收节奏

阶段	资金使用原则	必须提交的证据
批准后 1—2 周	先开预发布和必要服务，不一次全开	企业账号、正式报价、合同/退款/续费条款；10 名开发者分权
第 1 个月	保持现有生产可回退	真实录音上传/撤回、重复回执、账号隔离与恢复测试
第 2—3 个月	通过门槛再开双 Backend 与双 Worker	持久事件、跨实例互斥/幂等、采集峰值及 RTC 分项压测
第 3 个月检查点	累计不超过 60,000 元	实际消费、有效采集量、合格率、队列积压与单位有效小时成本
第 4—6 个月	通过复盘继续投入；预留额单批	训练导出与撤回追踪、备份恢复、容量趋势和下一期成本预测

验收目标需在压测前冻结，生产保护指标以仓库 Harness 规则为准，不因本预算文件放宽。任一跨账号泄露、撤回复活、无授权导出或账单异常均停止扩大流量；必要时退回单 Backend 和已验证的小流量模式，不删除数据。

十一、财务与审批执行

每周由技术负责人提交资源和 API 用量；财务每月对账，区分账户余额、已发生费用、已承诺合同及未到期赠额。建议 80%预算预警、100%停止新增非必要资源；这不是停止保存用户数据或直接关闭生产服务的授权。

充值前确认：账号归公司控制、实名认证与发票抬头、赠额生效时间及使用顺序、未使用余额退款条件、包年包月退订损失、自动续费策略、资源包地域限制及经销商/云市场费用是否可抵扣。除非专项批准，不作长周期 GPU 包销、不为补贴迁移账号与数据。

不包含的费用：用户采集报酬、10 名开发者工资、GPU 及训练热存储/50TB 持久存储/高速互联、大规模人工质检、法律合规与运营费用、子公司设立及办公成本、非阿里云订阅。它们需另有资金安排，不能将 12 万元称为项目全成本。

审批人：_____ 审批日期：_____

申请负责人：_____ 财务复核人：_____

审批意见：同意／调整后同意／暂缓。首次充值金额：_____；扩容需单独审批。

主要依据与适用说明

[L1] 当前项目摘要及《语音采集、扩容与控制面统一执行手册》；[L2] Web 数据采集说明与训练链路；[L3] livekit_agent/config.py。均为仓库记录/代码核对，本次未重新开展生产压测。

[A1] 阿里云百炼产品页；[A2] 百炼模型价格（北京地域指定型号）。[P1] 余杭 2026 年 8 月 6 日第二批伙伴拟认定公示；[P2] 杭州市 2026 年算力券兑付通知；[P3] 滨江杭高新〔2026〕6 号；[P4] 上海“模塑申城”沪经信智〔2026〕248 号。官方来源链接及核验限制见配套谈判文档“依据索引”。

参考原件：《上海、杭州算力政策及业务布局建议》，8 页，2026 年 9 月 7 日。本文为内部审批建议，不是云厂商报价、补贴资格认定或投资回报保证。后续商业条款以签署文件及主管部门确认口径为准。

官方来源链接

A1 · [大模型服务平台百炼 - 大模型应用构建 - 阿里云](#)

A2 · [阿里云百炼模型价格-大模型服务平台百炼\(Model Studio\)-阿里云帮助中心](#)

P1 · [关于拟认定余杭区算力伙伴（第二批）的公示](#)

P2 · [杭州市经信局（市数字经济局）关于组织开展 2026 年算力券兑付申报的通知](#)

P3 · [杭州高新开发区（滨江）管委会、政府关于印发杭州高新开发区（滨江）进一步加快新一代人工智能产业应用发展若干措施的通知](#)

P4 · [上海市经济信息化委关于组织 2026 年度上海市“模塑申城”工程相关补贴申报工作的通知](#)