

阿里云算力规划与商务谈判方案

第一期 3—6 个月 | 需求征询稿 | 2026 年 9 月 7 日

项目：生声不息/VoxFlame 拟签约主体：由双方核对实名认证、实际使用及发票主体后确定。

本稿供团队准备谈判及经负责人审阅后向阿里云征询；不构成采购订单、保底消费、GPU 交付承诺或补贴申报。内部充值申请金额和最高预算不作为供应商报价锚点，不在本稿披露。

一、合作目标与采购分包

第一期拟服务约 1,000 名用户、采集约 20,000 小时语音，支持 10 名开发者、主站、采集站与后续多应用。自研 ASR 为主，阿里云 ASR 为有限补充和故障回退，TTS 较少，LLM 用于表达纠错、对话、报告和记忆整理。

已有奇绩算力支持（团队提供，尚未核对支持合同、剩余额度与到期日）。阿里云合作优先解决基础云服务、API 额度、稳定连接、弹性 GPU 补充和后续同构扩容，而非立即替换已有支持。

询价包	范围	当前决策状态
A：基础云	CPU、业务 OSS、网络、状态服务、安全、日志与研发协作	优先报价，按里程碑开通
B：模型 API	ASR 回退、少量 TTS、Flash/Plus 文本处理、配额与赠额	固定模型、地域及账单规则后小规模验证
C：GPU 与训练存储	8×RTX 5090、8×H20 候选，持久存储及机房网络	独立报价和实测，未批准包租或采购
D：政策协同	服务商资格、可申报 SKU、费用明细与使用证明	阿里云提供材料，主管部门认定资格

请求阿里云提供两套可比较方案：①沿用奇绩 GPU、阿里云承接业务及必要补充；②阿里云或合规生态伙伴提供两台 GPU 候选。另列 3 个月、6 个月价格和按需/包月/短租可选项，不将 GPU 承诺消费与基础云优惠强制捆绑。

二、谈判优先顺序

先确认需求与资源可交付性，再按 SKU 拆分报价，随后谈折扣、赠额、试用、配额和账期；最后落实政策材料与验收退出条款。优先争取可验证的低总成本和弹性，不用宣传补贴上限替代现金流安排。

本次期望获得：具名技术与商务负责人、同口径书面报价、可预约的真实任务试机、配额书面答复、逐主体账单方案和合同偏离清单。产品能力和优惠未确认时，接受标注“未提供/待确认”，不接受口头承诺代替。

业务容量与 CPU 基础资源

三、分清六种容量

维度	第一阶段需求口径	不应混淆的边界
用户总量	约 1,000 名用户	不等于 1,000 名同时在线
总采集量	约 20,000 小时新增目标	既有约 10,000 小时为团队输入，来源与可训练比例待对账
平均录音并发	90 天约 28 人；180 天约 14 人	基于每天 8 小时，不含读题与休息
上传峰值场景	3 个月 80—150 路；6 个月 40—80 路	指突发上传压测，不能直接换算 RTC 路数
动态业务请求	总计约 3,000 万—5,000 万次	90 天 8 小时窗口平均约 11.6—19.3RPS，180 天约 5.8—9.6RPS；峰值须实测
实时 AI 会话	单 Worker 既有 8 路完整链路证据	双 Worker 先验证 16 路；不能承诺 80—150 路 RTC

现有采集界面包含实时识别，必须检查 80—150 路采集时是否同样占用 Agent。若每名采集者都要全程 RTC，本 CPU 配置不能直接满足目标。建议先用预约/准入控制限制实时识别，验证录音可保存、识别可排队的方案；未经实现与验收，不把它当作现成功能。[L1—L3]

16kHz 单声道 16-bit 音频约 256kbps。150 人连续产生原始音频约 38.4Mbps；若 150 人同时把各自 10 秒文件在 1 秒内补传，则瞬时约 384Mbps（均未含协议开销）。应测 OSS 直传和客户端补传行为，而不是给 Backend 购买同等音频中转带宽。

四、7 台 CPU 候选表

用途	数量	单台候选规格	开通条件
主站前端	1	4 vCPU／8GB	基础运行
第二前端、预发布及有界批处理	1	8 vCPU／16GB	第二品牌接线；CPU/内存隔离
Backend 控制面	2	4 vCPU／8GB	第二实例先备用，多实例安全验收后双写
LiveKit 媒体节点	1	8 vCPU／16GB	独立媒体入口、UDP/TURN 验证
Agent Worker	2	8 vCPU／16GB	集中配额、ASR 容量与真实 RTC 验收
总计	7	44 vCPU／88GB	候选容量，不是性能保证

要求报价注明实例族/代际、地域/可用区、系统盘与数据盘、带宽/EIP、流量/包月计费、折扣到期及续费价格。托管缓存、LB、数据库备份、SLS、镜像仓库单列，不藏入“7 台服务器”。

Backend 的持久事件与幂等以现有 Postgres/Supabase 为先，不为双实例新增第二套数据事实源。LiveKit 仍为单节点故障域；两台 Backend/Agent 不等于整站高可用。具体实施与保护指标遵循现役控制面手册及 Harness 规则。[L1]

GPU 算力规划：候选需求，不提前冻结型号

五、两个独立 GPU 节点

当前约 10,000 小时语音为团队提供的规划基础；第一期新增 20,000 小时是否与其重叠须确认。仅凭音频小时数，不能推出需要两台 8 卡 GPU，应以模型规模、训练配方、吞吐、频次、截止时间及既有支持可用量测算。

参数	节点一：训练主节点	节点二：吞吐/实验节点
GPU 候选	8×H20，准确料号/形态待确认	8×RTX 5090，准确地区型号待确认
拟承担任务	全参数训练、大显存及长序列任务	微调、数据处理、批量推理、评测
主机内存目标	1—2TB	512GB—1TB
本地 NVMe 目标	20—30TB 可用热数据空间	20—30TB 可用热数据空间
CPU 与拓扑	按供数实测选型；列双路/NUMA 及 PCIe 拓扑	明确 8 卡实际链路宽度、插槽与 NIC/SSD 争用
调度	与另一异构节点独立作业	以独立任务和数据并行为优先
当前状态	全部为候选需求，待书面报价/试机	整机可行性、供货与许可条件待确认

不混合两种 GPU 做同步训练。是否采用容器或现有任务调度工具，按团队工作流选择；10 名开发者共享任务队列、配额与项目空间，不承诺 10 人各自独占 GPU。在线自研 ASR 必须保留独立推理配额或实例，不能因离线训练抢占而迫使业务长期使用收费云 ASR。

六、需要在谈判前纠正的硬件假设

1. NVIDIA 公开的 RTX 5090 规格为单卡 32GB GDDR7、无 NVLink、显卡功耗 575W；8 卡显存算术合计 256GB，不是单一连续显存池，8 卡 GPU 功耗算术合计约 4.6kW，也不是整机功耗。该原厂页面不证明中国大陆可交付型号、八卡机箱兼容、机房托管及商业许可。[N1]
2. 必须让供方明确交付 5090、5090 D 或其他地区/后继型号，不接受只写“5090 级别”。确认制造商、显存、驱动/CUDA/训练框架兼容、P2P、散热、供电、噪声、质保及机房使用授权。无 NVLink 并不等于不能多卡计算，但扩展效率只能实测。
3. H20 不能仅凭型号简称推定显存容量、NVLink/NVSwitch 拓扑或供货日期。要求准确 SKU、每卡显存、互联拓扑、出口/销售合规材料、交付机房、维护支持和可替代型号；本次未取得一手 H20 配置文件或书面供货承诺。
4. 若阿里云不能提供这两种裸机，不假定其公共云有对应产品。要求分别报价合法可交付的大显存训练替代与高吞吐推理替代；若涉及生态伙伴，明确签约方、发票方、SLA 及数据处理责任。

替代基线：先试用奇绩现有资源和 1/2/4/8 卡方案，再比较“专属裸机、弹性云 GPU、现有支持+高峰短租”的每个有效训练任务总成本。未完成验证，不冻结 BOM 或承诺长租。

存储、网络与总成本边界

七、不要把三层存储当成三份原始数据

层级	候选容量与用途	报价、验收要求
业务数据层	6—10TB OSS，原录音、状态文件、标准化副本及备份	按平均占用、请求、下载、生命周期及恢复计费
训练持久层	约 50TB 可用逻辑空间，扩展至 100TB	可作为统一数据湖，包含上述业务数据的逻辑占用；若独立复制，另计传输与重复空间
训练热缓存	每台 20—30TB 本地 NVMe，共 40—60TB	可重建缓存，不是唯一备份；区分标称容量与 RAID 后可用容量
可选高性能共享层	20—40TB，仅真实共享训练需要时开通	可计入 50TB 或作为额外性能层，两种架构分别报价，禁止默认为免费叠加

50TB 属于训练专项，不能用基础云 6—10TB 预算自动覆盖。需按“原始音频+标准化音频+数据版本增量+推理结果+保留 checkpoint+备份+余量”核定。若累计 30,000 小时且不重叠，PCM 原音约 3.456TB，50TB 主要余量取决于 checkpoint 和版本保留策略，不由音频时长本身证明。

持久对象与训练缓存均用版本 manifest/校验和管理；小文件可在训练侧按不可变版本分片，但必须追踪用户撤回回到所有副本和未来训练导出。缓存可重建，未经授权不得删除原始音频；重复备份、临时盘、日志保留时间需分别设置且可审计。

八、区分机房内网络与云外传输

场景	规划目标	条件
管理、SSH、监控	10/25GbE	与数据平面隔离，按机房能力报价
GPU 到本地共享存储	100GbE 候选基线、200GbE 升级项	两个节点独立训练时先测 25/100GbE，不把 200G 当无条件必需
后续同构 H20 跨机训练	400GbE RoCE/RDMA 候选，GPUDirect RDMA 验证	同构扩容和通信实测证明必要后采购；不是当前两台异构节点必需
OSS 到奇绩或其他机房	实际专线/公网路径单列	云内免费范围、出网、跨地域复制、专线端口与线路费逐项确认

上述 GbE 是端口/链路候选速率，不是保证到 OSS 或互联网的实际吞吐。要求端到端带宽、超售比、NIC 数量、交换机、光模块、线缆、RDMA/RoCE 适配与部署边界。不能把 100/200/400GbE 机房网报价误当公网带宽。

应优先在同一地域并靠近热数据调度，避免每轮训练反复出云下载。总成本比较需加入 GPU 闲置、存储占用、冷热恢复、重复下载、网络、安全和运维；不能只比较“元／卡时”。

模型 API、额度和商业条款

九、模型 API 的谈判清单

项目	要求书面回答
ASR	指定当前 Qwen 实时型号与地域报价，计费秒数/最小粒度/静音口径；回退、对照合计按最多 2,000 小时做基准
TTS	指定型号及按字符/Token 计价口径；固定文案缓存的许可和存储要求
LLM	分 Flash/Plus、输入/输出、思考 Token、长上下文阶梯、Batch/缓存与重试计价
并发	分 ASR 实时连接数、TTS 并发、LLM RPM/TPM，列默认值、扩额条件、费用及生效时间
可用性	429/超时处理、区域异常、SLA 赔付及升级支持，回退不自动解除成本限额
赠额	是 Tokens、调用次数、Credits 还是人民币抵扣金；适用 SKU、领取人、有效期、消费顺序、叠加与余额查询
Token Plan	是何种订阅、是否允许生产多用户服务、是否覆盖本项目模型；专属 API Key、Endpoint 和迁移要求
凭证验证	在隔离环境用非敏感音频/文本做小额调用，检查具体账单抵扣，禁止将 Key 发入文档或邮件正文

百炼产品页同时出现“超 7000 万”和“超 1 亿 Tokens”免费体验表述，不能将总宣传额度当成一个可自由跨模型使用的钱包，也不能转换成“100 万元已获补助”。目前没有核验本公司新客资格或已领取额度。[A1]

尝试读取的 Token Plan 帮助地址返回 HTTP 200 的 404 内容页，不能据此确定专属 Key 或生产适用规则。该事项列为书面答复和试调用必答项；不提前更换线上凭证。

十、供方逐行报价模板

每一行均填写：产品/SKU、数量、地域/可用区、计量单位、使用量假设、目录价、折扣、税额及含税价、3 个月合计、6 个月合计、优惠期后续费价、赠额抵扣条件、是否有最低消费和报价有效期。

必须覆盖：ECS 及云盘、OSS 容量和请求、OSS 公网下载、EIP/TURN、LB 与处理单元、NAT/专线、托管状态服务、数据库/备份、SLS 写入及保留、ACR/构建、必要安全产品、ASR/TTS/LLM；GPU 包另列裸机、内存、NVMe、持久/共享存储、NIC/交换、托管/功耗是否包含、部署与退出费用。

总成本计算口径： 计算资源费用+存储实际 GB 月+业务请求/流量+GPU 节点月或卡时+网络/软件/服务费+税费－已确认可抵扣优惠。政策补助单列“未获批／部分获批／延后到账”情景，不先从应付现金中扣除。所有资源只能计一次。

十一、可交换条件与合同底线

可讨论以期限、稳定用量、增长评审及经单独许可的联合案例，交换折扣、赠额、试用、技术支持和配额。先看三个月短期运行数据，再决定是否转六个月或更长期；不提供未经批准的排他采购或保底 GPU 消费。

合同明确验收起算、故障停计/补偿、试用失败退出、降配/退订/退款、提前终止、余额/资源包失效、故障换机、数据导出和擦除证明。价格变化、资源型号替代、转包及数据地域变更须事先确认。涉及宣传、原始语音、个人身份或模型权重，不因云优惠自动授权对方使用。

结合上海、杭州政策的签约与费用安排

十二、按合格费用选择政策，不按充值总额测补助

政策路径	已有依据	本次向阿里云与主管部门确认
余杭	2026 年 8 月 6 日第二批伙伴公示已点名“阿里云计算有限公司”等拟认定单位，并引用 2026 修订细则	最终认定名单、准确法人、可支持 SKU、实际比例/限额、服务期；“拟认定”不是最终资格 [P1]
杭州市级	先获额度再兑付，2026 额度申领截至 12 月 10 日；材料列 2025 审计报告及 2026 服务期合同	新设主体替代材料、属地收件日期、GPU 服务范围与下一年度衔接 [P2]
滨江	新措施 2026 年 9 月 11 日施行；非自主/自主算力最高 30%/60%，单企最高 2,000 万元；Token 券按实际使用最高 1,000 万元	截至 9 月 7 日尚未施行；实际受理、费用起算、算力认定、年度额度及叠加规则 [P3]
上海市级	2026 通知支持非关联方智能算力租用，不包括存储/网络/安全；另有模型 API 和语料方向	本公司在沪经营资格、算力与模型项目、服务商统筹申报边界及季度通知 [P4]
西湖及上海 AI 小镇	原政策 PDF 列有相关支持方向与园区条件	仅在在有真实团队/业务落地时核验；未核对本次最新窗口，不据上限设主体 [原件]

“自主研发 ASR”不等于政策中的“自主人工智能算力”。不把 5090/H20 因运行自研模型就套用滨江 60%比例；也不把自采用户报酬自动列入“外购语料券”。两者均须依据具体认定口径。

阿里云说明资源与账单事实，政府主管部门决定资格、核定费用和拨付。政策上限不是承诺补贴；多法人也不当然允许同一项目或费用重复申报。免费奇绩支持、抵扣金抵扣部分及关联方转售如何认定，必须书面确认，未确认不列合格费用。

十三、签约前把证据链做对

按真实主体和项目建资源标签、预算及账单台账，保留合同、资源 ID、机房地域、服务日期、使用证明、付款流水、发票与交付成效。账号集中采购、子公司代付或集团转售应先确认政策是否接受，不事后转移母公司历史费用。

2026 年 9 月开始的六个月计划会跨 2027 年。报价和合同需分月列服务期；2026 年杭州通知只足以支持其所列 2026 期间要求，2027 政策及新批次仍待核验。杭州部门在 6 月、9 月、12 月和次年 2 月前 5 个工作日报送，不是企业统一截止日；上海后续季度批次也需以实际公告为准。[P2、P4]

经营上沿用原 PDF 原则：余杭现有业务先核费用，滨江/西湖新增布局跟随具体项目，上海客户与研发按真实主体承担。仓库已使用上海公司名，并不证明已存在可申报的余杭主体；各地实际主体、审计和税务资料需管理层先对账。不得仅为补贴重复设子公司。

验证、分期扩容与会议结论

十四、GPU 试机验收协议应先于长租

试验	必须固定的条件	决策证据
配置核对	GPU SKU、CPU/NUMA、显存、驱动、容器镜像、NIC/NVMe 拓扑	设备清单、可用容量、供货/许可与维护承诺
实际训练	授权且去标识的代表性语音集；模型、序列长度、精度、batch、优化器、随机种子	1/2/4/8 卡 samples/s、峰值显存、step P95、扩展效率、loss 及失败日志
长任务	至少 24 小时候选稳定性测试，实际时长由双方冻结	OOM/掉卡/过温、checkpoint 保存/恢复、异常重启及数据完整性
推理与在线共存	固定模型与说话人隔离评测，在线配额与离线资源隔离	CER 分层、真实短句/长停顿、噪声设备、ASR P95 及回退率
存储网络	冷缓存/热缓存、小文件/分片、恢复和校验；RDMA 仅在报价含该能力时测试	数据供给时间、持续吞吐、尾延迟、传输账单与重建时间
多用户协作	10 名开发者角色、任务配额、优先级、失败重试与空间隔离	无跨账号/项目读取，在线推理不被训练占满

不预填未经测试的训练速度。训练时长 $\approx$ 音频小时 $\times$ epoch $\div$ 整节点实测音频处理倍速，再计评测/checkpoint 开销；GPU 卡时还须乘实际使用卡数。用“每次合格训练任务成本”和“每千小时推理成本”比较供方，不用峰值算力代替业务性能。

十五、扩容与停止条件

第一步核对奇绩支持剩余资源、可用时段、存储/出网、数据许可及到期退出。第二步开基础云最小切片，验证账号、录音与持久事件。第三步完成采集/上传压力与 16 路 RTC 分项验证，再决定 GPU 补充与下一阶段并发。第四步仅在同构跨机训练瓶颈被证明后，讨论 400G 与更多 H20 节点。

停止条件：无法确认合法 SKU/使用授权；真实训练无法运行或性价比未优于既有资源；供方不提供拆项账单；采集量、补贴资格或用户权益被无依据承诺；出现越权、撤回复活、恢复失败或超过已批准预算。出现停止条件退回现有支持和小规模资源，不自动改生产、不删除原始数据。

十六、会后书面结论清单

请阿里云在首次技术商务会后按双方约定日期返回：

1. A/B/C 三个资源包的 3 个月与 6 个月含税报价、有效期及 SKU 偏离表。
2. 5090/H20 可交付情况、具体型号、机房、交付日期与替代方案。
3. 试用资源/额度、样本及测试协议、故障处理和退出条件。
4. ASR/TTS/LLM 并发、折扣、赠额、Token Plan 使用及凭证规则。
5. 余杭最终伙伴依据及上海/杭州可提供的服务证明、分账与申报协助材料。
6. 合同、账期、退订、SLA、数据导出及部署支持条款。

项目方：技术负责人核验容量和数据边界；财务负责人核验主体、报价、账单和政策材料；合伙人批准资金及长期承诺。双方确认材料不完整时，状态保持“继续征询”，不是默认同意采购。

依据索引与适用范围

核验时点：2026 年 9 月 7 日。原件与网页支持事实边界；候选规格、容量假设、分包、验收和谈判条件均为本项目提出的要求，不是厂商或政府保证。

阿里云及原厂依据

[A1] 阿里云《大模型服务平台百炼》产品页。公开免费额度宣传存在不同表述；不证明本账户权益。

[A2] 阿里云《百炼模型价格》。核验北京地域 qwen3-asr-flash-realtime-2026-02-10 及 qwen-flash 短上下文价格；别名/版本/地域变化需重新核价，不引用为长期锁价。

[N1] NVIDIA《GeForce RTX 5090 Graphics Cards》官方规格。仅支持该页面型号的单卡显存、无 NVLink、功耗等器件事实；不支持 H20 或大陆 8 卡裸机供货结论。

政策依据

[P1] 余杭区经信局、财政局《关于拟认定余杭区算力伙伴（第二批）的公示》，2026 年 8 月 6 日。已读网页正文，未读附件或取得最终名单及完整修订细则。

[P2] 杭州市经信局《关于组织开展 2026 年算力券兑付申报的通知》，落款 2026 年 5 月 29 日、网页发布 6 月 1 日。已读正文，未进入企业申报后台。

[P3] 杭州高新区（滨江）《进一步加快新一代人工智能产业应用发展若干措施》，杭高新〔2026〕6 号，2026 年 8 月 12 日发布、9 月 11 日施行。已读网页正文，不代表本公司资格获认定。

[P4] 上海市经信委《关于组织 2026 年度上海市“模塑申城”工程相关补贴申报工作的通知》，沪经信智〔2026〕248 号，2026 年 5 月 7 日。未独立核验本企业资料及后续批次。

项目依据与限制

[原件] 用户指定《上海、杭州算力政策及业务布局建议》，8 页，PDF 标题及文件类型已核对。SHA-256：3a7aa3602742922bdcac55bd2d688aefff296042f62ab4c625cb428be654fd12。

[L1] 仓库现役采集/扩容控制面手册及 2026 年 9 月 7 日会话摘要；[L2] Web 数据采集说明；[L3] livekit_agent/config.py。容量以现有验证记录为证，不作本次生产复测声明；与旧手册有部署状态冲突时，按最近摘要保留未完成边界。

通用网页检索未返回可用结果；Context7 仅取得百炼通用导航信息，因此改为直接读取阿里云、NVIDIA 及政府原文并留存哈希。Token Plan 候选地址实际为 404 内容，已记录失败，不作为规则依据。未获得正式资源报价、GPU 供货确认、公司补贴资格或独立财务/法务审核，文件仅供需求征询与内部审批准备。

网页原文入口见下方“官方来源链接”。法律、税务、数据使用和补贴资格由相应专业人员及主管部门确认；本稿不代替正式意见。

官方来源链接

A1 · 大模型服务平台百炼 - 大模型应用构建 - 阿里云

A2 · 阿里云百炼模型价格-大模型服务平台百炼(Model Studio)-阿里云帮助中心

N1 · GeForce RTX 5090 Graphics Cards | NVIDIA

P1 · 关于拟认定余杭区算力伙伴（第二批）的公示

P2 · 杭州市经信局（市数字经济局）关于组织开展 2026 年算力券兑付申报的通知

P3 · 杭州高新开发区（滨江）管委会、政府关于印发杭州高新开发区（滨江）进一步加快新一代人工智能产业应用发展若干措施的通知

P4 · 上海市经济信息化委关于组织 2026 年度上海市“模塑申城”工程相关补贴申报工作的通知